

Abgabe ADS2

Selbstständigkeitserklärung

Hiermit versichere ich, dass ich die vorliegende Arbeit selbstständig und ohne die Benutzung anderer als der angegebenen Hilfsmittel angefertigt habe. Alle Stellen - einschließlich Tabellen, Karten, Abbildungen etc. -, die wörtlich oder sinngemäß aus veröffentlichten und nicht veröffentlichten Werken und Quellen (dazu zählen auch Internetquellen) entnommen wurden, sind in jedem einzelnen Fall mit exakter Quellenangabe kenntlich gemacht worden. Zusätzlich versichere ich, dass ich beim Einsatz von generativen IT-/KI-Werkzeugen (z.B. ChatGPT, BARD, Dall-E oder Stable Diffusion) diese Werkzeuge in einer Rubrik "Übersicht verwendeter Hilfsmittel" mit ihrem Produktnamen, der Zugriffsquelle (z. B. URL) und Angaben zu genutzten Funktionen der Software sowie Nutzungsumfang vollständig angeführt habe. Wörtliche sowie paraphrasierende Übernahmen aus Ergebnissen dieser Werkzeuge habe ich analog zu anderen Quellenangaben gekennzeichnet. Mir ist bekannt, dass es sich bei einem Plagiat um eine Täuschung handelt, die gemäß der Prüfungsordnung sanktioniert werden wird. Ich versichere, dass ich die vorliegende Arbeit oder Teile daraus nicht bereits anderweitig innerhalb und außerhalb der Hochschule als Prüfungsleistung eingereicht habe.

Implementierung einer effizienten Datenstruktur für das Predecessor-Problem

Algorithmen und Datenstrukturen 2
Fachhochschule Bielefeld – Campus Minden
Bachelor of Computer Science
Wintersemester 2025/2026
Prof. Dr. Jörg Brunsmann

Teammitglieder

- Clemens Maas, 1260892

Inhaltsverzeichnis

- Einleitung
- Evaluation existierender Lösungsansätze
- Konzept der Datenstruktur
- Implementierung
- Optimierungen/Varianten (optional)
- Tests und Evaluation
- Benutzerdokumentation
- Lessons Learned
- Ausblick
- Literaturverzeichnis
- Anhang: Hilfsmittel

1. Einleitung

Das Predecessor-Problem ist ein grundlegendes Problem der Informatik: Gegeben eine dynamische Menge von Ganzzahlen, finde effizient den größten Wert, der kleiner oder gleich einem gegebenen Query-Wert ist.

Typische Anwendungen:

- Datenbanken: Range Queries und Indexstrukturen
- Netzwerke: Routing-Tabellen
- Algorithmik: Sweep-Line-Algorithmen / Event Scheduling

Aufgabenstellung

Implementierung einer Datenstruktur für eine geordnete Menge von Ganzzahlen im Bereich $[0, 2^w - 1]$ mit folgenden Operationen:

Operation	Beschreibung	Rückgabewert
<code>insert(x)</code>	Fügt Wert x ein	void
<code>delete(x)</code>	Löscht Wert x	void
<code>search(x)</code>	Prüft ob x vorhanden	bool
<code>indexOf(x)</code>	Liefert Index von x	i oder -1
<code>getAt(i)</code>	Liefert Wert an Index i	x oder null

<code>deleteAt(i)</code> Operation	Löscht Wert an Index i Beschreibung	x oder null Rückgabewert
<code>insertAt(i, x)</code>	Fügt x an Index i ein	void
<code>predecessor(z)</code>	Größter Wert $\leq z$ (inkl. Index)	(i, x) oder -1, -1
<code>successor(z)</code>	Kleinsten Wert $\geq z$ (inkl. Index)	(i, x) oder -1, -1
<code>min()</code>	Minimaler Wert	x oder null
<code>max()</code>	Maximaler Wert	x oder null
<code>isEmpty()</code>	Prüft ob leer	bool
<code>size()</code>	Anzahl Elemente	n

2. Evaluation existierender Lösungsansätze

2.1 Sortiertes Array

- Insert/Delete: $O(n)$ (Verschieben)
 - Search/Pred/Succ: $O(\log n)$
 - getAt: $O(1)$
 - Speicher: $O(n)$
- Bewertung: ☹ Ungünstig bei häufigen Updates.

2.2 Hash Table

- Insert/Delete/Search: $O(1)$ erwartet
 - Pred/Succ/getAt: nicht effizient (keine Ordnung)
- Bewertung: ☹ Für das Predecessor-Problem ungeeignet.

2.3 (Unbalancierter) BST

- durchschnittlich: $O(\log n)$
 - Worst-Case: $O(n)$
- Bewertung: ⚠ Keine Worst-Case-Garantie.

2.4 AVL-Tree

- $O(\log n)$ garantiert (strenger balanciert)
- Bewertung: ☹ Sehr gut, aber höhere Implementierungskomplexität.

2.5 Red-Black Tree

- Insert/Delete/Search/Pred/Succ: $O(\log n)$ garantiert
 - getAt/indexOf mit Order Statistics: $O(\log n)$
 - Speicher: $O(n)$
- Bewertung: ☹ **Gewählt** – gute Balance aus garantierter Laufzeit und Implementierbarkeit.

2.6 van Emde Boas Tree

- $O(\log \log u)$, aber Speicher $O(u)$
- Bewertung: ☹ für $w=32/64$ praktisch zu groß.

3. Konzept der Datenstruktur

3.1 Red-Black Tree mit Order Statistics

Gewählter Ansatz: Augmentierter Red-Black Tree, bei dem jeder Knoten die Größe seines Teilbaums speichert (`size`).

3.1.1 Node-Struktur (konzeptionell)

```
const Node = struct {
    value: T,
    color: Color,      // Red/Black
    left: ?*Node,
    right: ?*Node,
    parent: ?*Node,
    size: usize,       // Teilbaumgröße
};
```

3.1.2 Invarianten

Red-Black Eigenschaften (klassisch):

1. Root ist schwarz
2. Rote Knoten haben schwarze Kinder
3. Alle Pfade von einem Knoten zu null-Blättern enthalten gleich viele schwarze Knoten

Order Statistics:

- `node.size = 1 + size(left) + size(right)`
- Größen müssen bei Insert/Delete/Rotation korrekt aktualisiert werden.

3.1.3 Pseudocode (zentral)

Select (`getAt`):

```
SELECT(node, i):
    left_size = SIZE(node.left)
    if i == left_size: return node
    if i < left_size: return SELECT(node.left, i)
    return SELECT(node.right, i - left_size - 1)
```

Rank (`indexOf`):

```
RANK(node):
    rank = SIZE(node.left)
    current = node
    while current.parent != null:
        if current == current.parent.right:
            rank += 1 + SIZE(current.parent.left)
        current = current.parent
    return rank
```

4. Implementierung

4.1 Technologie-Stack

- Programmiersprache: Zig 0.15 (0.15.2 beim Language Server)
- Single-threaded, explizite Speicherverwaltung via Allocator

4.2 Modul-Struktur (relevant)

Die Hauptdatenstruktur ist `src/rb_tree.zig`. Zusätzliche Dateien (z. B. Varianten/Experimente) sind optional und nicht notwendig, um die ADT-Funktionalität zu erfüllen.

4.3 Wichtige Design-Entscheidungen

1. Generische Implementierung: `RedBlackTree(comptime T: type)`
2. Explizites Memory Management über `Allocator`
3. Min/Max Caching (`min_cache`, `max_cache`) für $O(1)$ Zugriff auf Minimum/Maximum.
4. `size`-Tracking pro Knoten für `getAt` / `indexOf`.

5. Optimierungen/Varianten (optional)

Dieser Abschnitt beschreibt optionale Erweiterungen/Varianten, die nicht zwingend Teil der Basislösung sind.

5.1 Node Pooling (Variante)

Eine mögliche Variante ist Node Pooling (Freelist), um bei Insert/Delete-Zyklen weniger oft `allocator.create/destroy` aufzurufen. Diese Technik kann konstante Faktoren in update-lastigen Workloads verbessern, ändert aber die asymptotischen Komplexitäten nicht.

5.2 Bulk-/SIMD-Ideen

Bulk-Operationen und SIMD sind potenziell sinnvoll bei sehr speziellen Workloads, stehen aber nicht im Fokus der geforderten ADT-Operationen und der Evaluation in Abschnitt 6.

6. Tests und Evaluation

6.1 Unit Tests (Kurzüberblick)

Wir testen u. a. Insert/Delete/Search sowie Index-Operationen und Predecessor/Successor inkl. Randfällen (leerer Baum, 1 Element, Out-of-Bounds).

Aufruf der Tests mit:

```
zig run test
```

6.2 Evaluation (Aufgabe 1.3)

Ziel: Laufzeit und genutzten Speicherplatz messen, grafisch darstellen und mit der Theorie vergleichen.

6.2.1 Messmethodik

- Benchmark erzeugt `bench.csv`.
- Mehrere Samples pro Datensatzgröße `n` (Median + Streuung) für stabilere Aussagen.
- Plots werden mit Python/Matplotlib erzeugt.
- Warmup um die Streuung zu minimieren.

6.2.2 Laufzeit-Plots

- `plots/time_search_hit.png`
- `plots/time_predecessor.png`
- `plots/time_cycles_insert_delete.png`

Erwartung (Theorie): Für Search/Predecessor/Updates erwarten wir $O(\log n)$ pro Operation aufgrund der Baumhöhe eines balancierten Suchbaums. **Beobachtung (Messung):** Die gemessene `ns/op` wächst deutlich langsamer als linear mit `n` und ist konsistent mit dem erwarteten logarithmischen Verhalten.

Zusätzlich werden Speedup-Grafiken als „paired speedup“ dargestellt, um Varianz zu reduzieren:

- `plots/speedup_search_hit_paired.png`
- `plots/speedup_predecessor_paired.png`
- `plots/speedup_cycles_paired.png`

6.2.3 Speicher-Plot ($O(n)$ -Check)

- `plots/memory_insert_peak.png`

Erwartung (Theorie): $O(n)$ Speicher, da pro Element ein Node existiert. **Beobachtung (Messung):** Der Peak-Speicher wächst proportional zu `n` und folgt der Referenzlinie `n * sizeof(Node)`, wodurch $O(n)$ bestätigt wird.

7. Benutzerdokumentation

7.1 Kompilierung

```
zig build
```

Optional (optimiert):

```
zig build -Doptimize=ReleaseFast
```

7.2 Verwendung (Beispiel | Deutliches Beispiel ist in `main.zig` vorhanden)

```

const std = @import("std");
const rb = @import("rb_tree");

pub fn main() !void {
    var gpa = std.heap.GeneralPurposeAllocator(.{}){};
    defer _ = gpa.deinit();

    var tree = rb.RedBlackTree(i32).init(gpa.allocator());
    defer tree.deinit();

    try tree.insert(10);
    try tree.insert(5);
    try tree.insert(15);

    if (tree.search(10)) {
        std.debug.print("Found 10!\n", .{});
    }

    if (tree.getAt(1)) |value| {
        std.debug.print("Element at index 1: {}\n", .{value});
    }

    if (tree.predecessor(12)) |pred| {
        std.debug.print("Predecessor of 12: index={}, value={}\n", .{pred, pred});
    }
}

```

Hinweis: predecessor liefert ein Tupel { i64, T } .

7.3 Benchmarks ausführen und visualisieren

```

zig build bench
python scripts/bench_plot.py

```

Die Plots werden unter plots/ abgelegt, relativ vom Pfad aus dem man das Skript startet.

python dependencies installierbar mit

```

pip install -r scripts/requirements.txt

```

7.4 Tests ausführen

```

zig build test --summary-all

```

7.5 Beispiel aufrufen (oder direkt als Binary nach dem bauen)

```

zig build run

```

8. Lessons Learned

- Korrekte size-Updates sind essenziell (insbesondere bei Rotationen), sonst brechen getAt / indexOf .
- Microbenchmarks haben sehr oft eine Streuung; mehrere Samples und robuste Kennzahlen waren notwendig um eine gute Visualisierung zu bekommen.
- RB-Tree Delete-Fixup ist der fehleranfälligste Teil; Tests auf Randfälle sind entscheidend. (Hier habe ich auch die meiste Zeit verbracht)
- Immer mal wieder den Zig-Cache leeren bringt etwas. Viele Fehler haben sich dadurch behoben.

9. Ausblick

- Weitere Workloads (z. B. gemischte Operationen mit festen Anteilen) könnten die Messungen näher an reale Anwendungen bringen.
- Optional: Node Pooling Variante könnte konstante Faktoren bei Insert/Delete-Zyklen reduzieren.

10. Quellen

Quellen habe ich beim aufrufen + nachtraeglich aus meinem Browser kopiert und Minimax zum formatieren gegeben:

Kategorie · Thema	Link
Grundproblem · Predecessor problem	https://en.wikipedia.org/wiki/Predecessor_problem en.wikipedia
Theorie/Survey · Optimal Bounds for the Predecessor Problem (Beame & Fich)	https://homes.cs.washington.edu/~beame/papers/stocpred.pdf homes.cs.washington
Theorie/Survey · Predecessor Search (PDF)	https://repositorio.uchile.cl/bitstream/handle/2250/178791/Predecessor-Search.pdf repositorio.uchile
BST-Grundlagen · Binary search tree	https://en.wikipedia.org/wiki/Binary_search_tree en.wikipedia
Balancierte BST · AVL tree	https://en.wikipedia.org/wiki/AVL_tree en.wikipedia
Balancierte BST · Red–black tree	https://en.wikipedia.org/wiki/Red%E2%80%93black_tree en.wikipedia
Mehrweg-Bäume · B-tree	https://en.wikipedia.org/wiki/B-tree en.wikipedia
Mehrweg-Bäume · B-Trees (Lecture Notes)	https://www.cs.gordon.edu/courses/cs321/lectures/Btrees.html cs.gordon
Integer-Strukturen · van Emde Boas tree	https://en.wikipedia.org/wiki/Van_Emde_Boas_tree en.wikipedia
Integer-Strukturen · X-fast trie	https://en.wikipedia.org/wiki/X-fast_trie en.wikipedia
Integer-Strukturen · Y-fast trie	https://en.wikipedia.org/wiki/Y-fast_trie en.wikipedia
Integer-Strukturen · Predecessor Data Structures (Slides/PDF)	https://massivedatasets.wordpress.com/wp-content/uploads/2011/02/predecessor_2011.pdf massivedatasets.wordpress
Randomized · Skip list	https://en.wikipedia.org/wiki/Skip_list en.wikipedia
Randomized · Treap	https://en.wikipedia.org/wiki/Treap en.wikipedia
Order Statistics · CLRS Ch. 14 (Augmenting Data Structures)	https://euroinformatica.ro/documentation/programming/!!!Algorithms_CORMEN!!!/DDU0081.html euroinformatica
Order Statistics · CLRS Ch. 14 (PDF Notes)	https://sites.math.rutgers.edu/~ajl213/CLRS/Ch14.pdf sites.math.rutgers
Order Statistics · CLRS 14.1 (Solutions)	https://walkccc.me/CLRS/Chap14/14.1/ walkccc
Benchmarking · Reducing variance (Google Benchmark)	https://github.com/google/benchmark/blob/main/docs/reducing_variance.md github
Benchmarking · Random interleaving (Google Benchmark)	https://google.github.io/benchmark/random_interleaving.html google.github
Benchmarking · User guide (Google Benchmark)	https://google.github.io/benchmark/user_guide.html google.github
Zig · Language Reference	https://ziglang.org/documentation/master/ ziglang
Zig · Standard Library docs	https://ziglang.org/documentation/master/std/ ziglang
Zig Bench · doNotOptimizeAway (Ziggit thread)	https://ziggit.dev/t/how-to-use-std-mem-donotoptimizeaway/4677 ziggit
Zig Bench · Constant folding pitfall (blog)	https://pyk.sh/blog/2025-12-08-bench-fixing-constant-folding pyk

Kategorie · Thema	Link
Zig 0.15.1/O · Reader/Writer overhaul	https://dev.to/bkataru/zig-0151-io-overhaul-understanding-the-new-readerwriter-interfaces-30oe dev
Matplotlib · fill_between demo	https://matplotlib.org/stable/gallery/lines_bars_and_markers/fill_between_demo.html matplotlib

11. Anhang: Hilfsmittel

KI-Werkzeuge

MiniMax 2.1 (lokal gehostetes LLM)

- Wurde nicht zur direkten Code-Generierung benutzt
- Genutzte Funktionen:
 - Debugging-Hilfe (Fehler-Analyse)
 - Verbesserung der Code-Kommentierung und Dokumentation (Rechtschreibfehler + "bessere Sprache")
 - Ideenfindung und "Diskussion" zu Optimierungen
- Nutzungsumfang:
 - iterativ während Implementierung und Evaluation

Software/Tools

- Zig (v0.15 / zls v0.15.2)
- Python 3 + Matplotlib
- Git
- TeamCity (CI-Pipeline im lokalen Netzwerk)